



UFRJ

O Mapeamento de Nitossolos no Brasil com o uso de Machine Learning

Caroline S Oliveira

O solo e o Território Nacional

O solo como recurso critico:

Base para a segurança alimentar, sustentabilidade ambiental e desenvolvimento agrícola nacional.

O **SiBCS** (Embrapa):

O Sistema Brasileiro de Classificação de Solos é o sistema taxonômico oficial do Brasil.

Objetivo do Sistema:

Estrutura hierárquica, multicategórica e aberta desenvolvida desde a década de 1970 para padronizar e classificar a diversidade pedológica em todo o território nacional

O Desafio dos Dados: A Classificação da Embrapa

Universo da análise:

Dataset extraído do site da Embrapa contendo **2854 amostras** e **20 atributos** preditores


Variedade taxonômica:

O SiBCS divide os solos mapeados em **13 ordens** distintas de grande relevância agronômica.

O Problema do Desbalanceamento:

A distribuição de classes no território brasileiro é altamente desigual, gerando desafios severos para a modelagem preditiva tradicional.

Composição Ocupacional dos Solos Brasileiros (%)



O Solo Escolhido: As Características do Nitossolo

Distribuição Geográfica dos Nitossolos no Brasil
(Amostras do Dataset Oficial)

O que é o Nitossolo:

Solo profundo, bem drenado, com argila de atividade baixa ou caráter alumínico marcante.

Propriedades Físicas Tradicionais:

Textura argilosa ou muito argilosa, estrutura em blocos subangulares ou prismáticos, e forte presença de **cerosidade** nas superfícies dos agregados.

Importância Agronômica:

Apresenta alto valor agrícola, grande potencial produtivo e excelentes propriedades físicas para o cultivo.



Replicabilidade do Sistema

Base de dados: dataset extraído do site oficial da Embrapa

IDE: Google Colab

Software: Python 3.12.13

Bibliotecas:

Matplotlib: 3.10.0

Pandas: 2.2.2

Seaborn: 0.13.2

Sklearn: 1.6.1

Imblearn: 0.14.2

O problema abordado no estudo:

PREDOMINÂNCIA TERRITORIAL

Três classes de solo correspondem a cerca de 70% dos dados que compõem o dataset

NITOSSOLO

Classe de alto valor agrônômico mas com baixa quantidade de amostras. **Representando cerca de 1,79% dos dados do dataset**

MODELOS DE MACHINE LEARNING TENDEM A IGNORAR CLASSES MINORITÁRIAS

Os modelos de Machine Learning tendem a **desconsiderar classes com pouca representatividade na preparação dos seus modelos de treinamento**. Tornando as classes minoritárias invisíveis.

Nitossolos

1,8%

Luvissolos

2,2%

Planassolos

2,5%

Espondossolos

3,4%

Cambissolos

4,9%

Plintossolos

6,7%

Gleissolos

12,1%

Neossolos


17,3%

Latossolos

25,3%

Argissolos

21,8%



Metodologia

Random Forest

Definição Base:

É um classificador em conjunto composto por uma coleção de árvores de decisão estruturadas de forma independente.

O Princípio da Aleatoriedade:

Cada árvore é gerada a partir de um vetor aleatório amostrado de forma independente, mas com a mesma distribuição para todas as árvores da floresta.

A Dupla Injeção de Casualidade:

1. Amostragem (Bagging): Cada árvore treina com um subconjunto aleatório dos dados originais.
2. Seleção de Atributos: Em cada nó da árvore, o melhor corte (split) é escolhido a partir de um subconjunto aleatório de variáveis preditoras (colunas), e não de todas.


Mecanismo de Decisão:

Cada árvore gera uma predição individual. O resultado final é determinado pelo voto majoritário (classificação) ou pela média das respostas.


A Teoria da Convergência:

Breiman provou através da Lei Forte dos Grandes Números que o erro de generalização converge para um limite à medida que o número de árvores cresce. Isso significa que o modelo é extremamente robusto contra o overfitting.

Decision Tree




Random Forest



Metodologia

Smote


A tecnica SMOTE (Synthetic Minority Over-Sampling Technique) foi criada para lidar com problemas de desequilíbrio de classes em algoritmos de aprendizado de máquina. A ideia é realizar uma sobreamostragem dos eventos raros antes de executar um algoritmo de classificação de aprendizado de máquina. No entanto, em sua essência, o algoritmo SMOTE (Chawla et al., 2002) é essencialmente uma maneira de simular novos dados sintéticos a partir de dados reais.




Metodologia

Adasyn

ADASYN é uma extensão da Técnica (SMOTE). Na tecnica SMOTE criam-se observações sintéticas usando todos os exemplos da classe minoritária como modelos. A ADASYN, por sua vez, concentra-se em gerar amostras sintéticas em áreas onde a classe minoritária é mais difícil de aprender, ou seja, onde a classe minoritária está pouco representada. Dessa forma, a ADASYN deve aprimorar a capacidade do classificador de discernir melhor os limites entre os exemplos da classe minoritária e da classe majoritária, ou pelo menos, essa é a teoria.



Resultados Obtidos




A partir do gráfico observa-se que ambas as técnicas apresentam desempenho baixo para as métricas analisadas.

Observa-se também um alto índice de falsos positivos.

Essa baixa precisão do modelo indica que **o Nitossolo ainda é erroneamente classificado**, em ambas as técnicas.

Conclui-se que ao limitar a síntese de dados a três atributos **criou-se um subespaço linearmente pobre com a geração de dados sintéticos sobrepostos às classes majoritárias**, o que gerou confusão ao modelo classificador.

A expansão do espaço de características deu ao algoritmo de superamostragem os graus de liberdade necessários para segregar os Nitossolos



O **Smote** apresentou excelente equilíbrio e viabilidade estatística, apresentando **Precisão de 85%, Recall de 79%** e **F1-Score de 81%**. Este modelo de fato aprendeu a generalizar classes minoritárias, como o Nitossolo.

O **Adasyn** apresentou a marca perfeita de 100% em todas as métricas. Mas ao invés de dizer que obtivemos o cenário ideal, observa-se um cenário de **overfitting** severo devido às características do algoritmo.

Por gerar dados sintéticos focados quase que exclusivamente nas amostras mais difíceis da fronteira, o ADASYN criou "ilhas" ou nuvens hiperdensas de Nitossolos artificiais no espaço hexadimensional. O Random Forest simplesmente **decorou** esses hiperplanos restritos, gerando uma separabilidade artificial perfeita.

Considerações Finais

A Importância dos Atributos (Grupo 1 vs. Grupo 2): Quantidade de dados não substitui a qualidade da informação. Utilizar apenas 3 colunas (Grupo 1) causou underfitting, misturando os Nitossolos com as classes majoritárias.

O Impacto do Espaço Hexadimensional: A expansão para 6 colunas (Grupo 2) deu a separabilidade necessária para os algoritmos entenderem a assinatura da classe alvo.

A Armadilha do ADASYN: Métricas perfeitas (1,00) no Grupo 2 mascararam uma memorização estrita (overfitting), tornando o modelo incapaz de lidar com novos dados reais.

Modelo Homologado: O Random Forest combinado com SMOTE (6 colunas) é a solução recomendada, atingindo o melhor equilíbrio prático de generalização (F1-Score: 0,81)



UFRJ

Agradeço sua atenção!

Caroline S Oliveira
caroline.oliveira@ufrj.br