

O Mapeamento de Nitossolos no Brasil com o uso de Machine Learning

Caroline Silva de Oliveira ^{1,2}, Jorge Zavaleta ^{1,2}, Sergio Manuel Serra da Cruz ^{1,3}

Programa de Pós-Graduação em Informática - UFRJ - BRASIL ¹

{caroline, zavaleta}@pet-si.ufrj.br ², sergioserra@ic.ufrj.br ³

Resumo

O presente estudo aborda o desafio de mapear digitalmente os Nitossolos no Brasil, cuja presença no banco de dados geoespaciais oficial da Embrapa é de apenas 1,79%, inviabilizando sua identificação em modelos tradicionais devido ao desbalanceamento de classes. Para superar esse entrave, foram avaliadas a aplicação das técnicas de sobreamostragem sintética SMOTE e ADASYN combinadas aos algoritmos de aprendizado de máquina *Random Forest* e *k-Nearest Neighbors* (k-NN) em diferentes subconjuntos de atributos preditores. Os experimentos demonstraram que a adição de variáveis e a escolha do modelo foram determinantes, destacando-se a combinação de *Random Forest* com SMOTE (no Grupo 2 de atributos) como a abordagem mais equilibrada e robusta, alcançando F1-Score de 0,81 e precisão de 0,78 para a classe minoritária. Em contrapartida, o uso do ADASYN com *Random Forest* indicou ocorrência de *overfitting*, enquanto o k-NN exigiu a otimização de hiperparâmetros para neutralizar distorções de vizinhança causadas pelos dados sintéticos. Conclui-se que o balanceamento sintético associado à seleção criteriosa de variáveis e ao ajuste fino dos classificadores é eficaz para resgatar os Nitossolos da sub-representação estatística e viabilizar seu mapeamento preditivo.

Abstract

This study addresses the challenge of digitally mapping Nitisols in Brazil, whose presence in Embrapa's official geospatial database is only 1.79%, making their identification in traditional models unfeasible due to class imbalance. To overcome this obstacle, the application of synthetic oversampling techniques SMOTE and ADASYN combined with the machine learning algorithms Random Forest and k-Nearest Neighbors (k-NN) across different subsets of predictive attributes was evaluated. The experiments demonstrated that the addition of variables and the choice of model were decisive, highlighting the combination of Random Forest with SMOTE (in Attribute Group 2) as the most balanced and robust approach, achieving an F1-Score of 0.81 and a recall of 0.78 for the minority class. In contrast, the use of ADASYN with Random Forest indicated the occurrence of overfitting, while k-NN required hyperparameter optimization to neutralize neighborhood distortions caused by the synthetic data. It is concluded that synthetic balancing, associated with careful variable selection and fine-tuning of the classifiers, is effective in rescuing Nitisols from statistical underrepresentation and enabling their predictive mapping.

Palavras-chave

Nitossolos, Desbalanceamento de Classes, SMOTE, ADASYN, Random Forest, k-NN

1. Introdução

1.1. Contexto e Relevância

O solo é um recurso finito e essencial à manutenção da vida no planeta (Koch et al., 2013), desempenhando papel relevante no equilíbrio dos ecossistemas por meio do controle das emissões de carbono e da conservação da biodiversidade (Serra Da Cruz et al., 2018). Essa importância exige estratégias de manejo que evitem a degradação desse recurso. No contexto brasileiro, os Nitossolos destacam-se pelo valor agrícola, apresentando bom potencial produtivo e características físicas favoráveis ao cultivo. Contudo, apesar de sua importância socioeconômica e agrônômica, cobrem apenas cerca de 1,78% do território nacional, o que demanda mapeamento preciso e planejamento adequado de uso.

De acordo com o Sistema Brasileiro de Classificação de Solos (Santos et al., 2018), os Nitossolos constituem uma ordem mineral com horizonte B nítico posicionado imediatamente abaixo do horizonte A (exceto quando este for A chernozêmico). Entre suas propriedades diagnósticas, destacam-se a textura argilosa a muito argilosa ao longo de todo o perfil e a estrutura em blocos subangulares, angulares ou prismáticos de grau moderado a forte, associada à cerosidade na superfície dos agregados (Santos et al., 2018). São solos bem a excessivamente drenados, de coloração avermelhada a bruna, cujas transições entre os horizontes A e B ocorrem tipicamente de forma gradual ou difusa (Santos et al., 2018), como ilustrado na Figura 1.



Figura 1 - Perfil de Nitossolo exibindo transição gradual de horizontes e estrutura diagnóstica típica do horizonte B nítico.

Fonte: Adaptado de Embrapa Solos.

A complexidade dessas feições morfológicas torna a identificação manual dos Nitossolos um processo demorado e dependente de conhecimento especializado. A integração entre pedologia e recursos computacionais surge, portanto, como forma de otimizar o reconhecimento pedológico. Nesse sentido, este estudo tem como objetivo desenvolver uma técnica baseada em aprendizado de máquina (*machine learning*) para identificar e classificar o Nitossolo de forma automatizada e precisa, utilizando o acervo técnico oficial da Empresa Brasileira de Pesquisa Agropecuária (Embrapa).

1.2. Problema de Pesquisa

Apesar dos Nitossolos possuírem grande importância ecológica e econômica, devido a sua riqueza de nutrientes, sua ocorrência geográfica no território nacional é bem pontual. Utilizando a base de dados oficial da Embrapa, que contém 2.854 registros e 20 atributos químicos e físicos dos solos, os nitossolos possuem apenas 48 amostras, ou seja 1,79% do total. Quando algoritmos tradicionais de aprendizado de máquina são treinados com dados

extremamente desbalanceados, como neste caso, eles tendem a negligenciar as classes minoritárias. O que torna os nitossolos invisíveis nos modelos de análise preditiva de dados.

A figura 2 mostra a distribuição dos nitossolos no território nacional.




Figura 2 - Distribuição dos Nitossolos no Brasil

1.3. Objetivo Geral e Específicos

O objetivo geral deste estudo é analisar e comparar a eficácia de técnicas de reamostragem sintética para melhorar a detecção preditiva dos nitossolos utilizando técnicas de *Machine Learning*.

Os objetivos específicos são:

- Aplicar os algoritmos de geração de dados sintéticos *SMOTE* e *ADASYN*;
- Avaliar o impacto das abordagens usando os classificadores *Random Forest* e *k-NN*;
- Avaliar a influência do número de atributos preditores (grupo 1 e grupo 2) na capacidade de generalização dos modelos com *Random Forest*;

- Comparar as métricas de avaliação dos classificadores *Random Forest* e *k-NN* para classificação de Nitossolos.

1.4. Organização do Trabalho

Para alcançar os objetivos propostos, este trabalho está estruturado da seguinte forma: a próxima seção apresenta o **Referencial Teórico**, abordando a literatura sobre classificação de solos e o tratamento de dados desbalanceados. Em seguida, a **Metodologia** detalha os dados geoespaciais utilizados, a seleção de atributos e as etapas de treinamento dos algoritmos *Random Forest* e *k-NN*, combinados aos métodos SMOTE e ADASYN. A seção de **Resultados e Discussão** traz a análise do desempenho dos modelos, focando na identificação dos Nitossolos e nos efeitos de vizinhança. Por fim, a **Conclusão** reúne as considerações finais, as limitações do estudo e as propostas para trabalhos futuros.

2. Referencial Teórico

2.1 *Random Forest*

O *Random Forest* (Breiman, 2001) é um algoritmo de aprendizado de máquina supervisionado baseado em *ensemble learning*, técnica que combina múltiplos modelos preditivos para atenuar os erros individuais e aumentar a estabilidade das estimativas. Estruturado a partir de árvores de decisão, o método é aplicado a problemas de classificação e regressão.

O funcionamento do algoritmo baseia-se na inserção de dois mecanismos de aleatoriedade durante a fase de treinamento:

- **Amostragem dos dados (*Bagging*):** Cada árvore é ajustada em um subconjunto de dados gerado por amostragem aleatória com reposição (*bootstrap*) a partir do conjunto de treino original.
- **Seleção aleatória de atributos (*Feature Randomness*):** Diferente das árvores convencionais, que avaliam todas as variáveis para definir a melhor divisão de cada nó, o *Random Forest* sorteia um subconjunto restrito de atributos em cada etapa de decisão.

Essa abordagem reduz a correlação entre as árvores e diminui a sensibilidade do modelo a ruídos ou a variáveis específicas.

A resposta final do modelo resulta da agregação das previsões individuais: por votação majoritária nos casos de classificação, ou pela média simples dos valores preditos nas tarefas de regressão.

Essa arquitetura confere ao *Random Forest* maior resistência ao *overfitting*, uma vez que a combinação de árvores diversificadas reduz a variância global do modelo. Além disso,

a técnica permite o uso das amostras *Out-Of-Bag* (OOB) — dados não incluídos no treino de cada árvore — para estimar o erro de generalização sem a necessidade de uma etapa adicional de validação, viabilizando também o cálculo da importância relativa das variáveis.

2.2 k-NN

O algoritmo *k-Nearest Neighbors* (*k-NN*) é um método supervisionado não paramétrico baseado em instâncias, classificado como uma técnica de *lazy learning*. Seu princípio assume que dados com atributos semelhantes ocupam regiões próximas no espaço amostral. Dessa forma, o algoritmo não constrói um modelo preditivo na etapa de treino; as estimativas para novas observações são processadas apenas no momento da consulta, calculando a distância em relação às instâncias conhecidas. Desenvolvido inicialmente por Fix e Hodges (1951) e ampliado por Cover e Hart (1967), o método é empregado em tarefas de classificação, regressão, sistemas de recomendação e mineração de dados.

Na manipulação de dados, a técnica aplica-se em duas abordagens principais. A **Busca *k-NN*** identifica, a partir de um ponto de consulta q em um espaço d -dimensional, os k elementos mais próximos com base em uma métrica de distância. A **Junção *k-NN*** estende essa lógica para relacionar dois conjuntos de dados distintos (D_1 e D_2), retornando os k vizinhos em D_2 para cada observação presente em D_1 .

A execução do algoritmo segue três passos principais. Primeiro, define-se o hiperparâmetro k , correspondente ao número de vizinhos consultados. Em seguida, calcula-se a distância (como a Euclidiana, Manhattan ou Minkowski) entre o novo ponto e os dados da base, ordenando os valores obtidos. Por fim, faz-se a agregação das respostas: por votação majoritária para classificação, ou pela média (ou mediana) dos valores para regressão.

2.3. SMOTE

O *Synthetic Minority Over-sampling Technique* (SMOTE), originalmente proposto por Chawla et al. (2002), é uma das técnicas de sobreamostragem mais difundidas para minimizar o problema do desbalanceamento de classes em conjuntos de dados de classificação. Diferente de métodos tradicionais de amostragem que apenas duplicam instâncias existentes, o SMOTE atua gerando amostras sintéticas para a classe minoritária por meio da interpolação de valores de atributos entre uma instância selecionada e um de seus k -vizinhos mais próximos (k -NN) no espaço de características. Esse processo expande o conjunto de dados de treinamento e melhora a representatividade da classe minoritária, resultando no aumento do desempenho dos classificadores.

Apesar da ampla adoção, a literatura aponta limitações na versão original do algoritmo. O SMOTE tradicional costuma desconsiderar a distribuição espacial da classe minoritária e a presença de ruídos nos dados. Como consequência, o método pode sobregeneralizar essa classe e induzir o modelo a erros na classificação de instâncias da classe majoritária.

Esse problema se agrava diante de observações atípicas (*outliers*) na classe minoritária. Quando selecionadas para a interpolação, essas instâncias levam à criação de amostras sintéticas em regiões inadequadas do espaço amostral. Esse efeito distorce a fronteira de decisão entre as classes, enviesando o modelo e reduz sua capacidade de generalização.

2.4 Adasyn

O *Adaptive Synthetic Sampling Approach for Imbalanced Learning* (ADASYN) é uma técnica de sobreamostragem sintética (*oversampling*) desenvolvida por He et al. (2008) para lidar com o problema do aprendizado a partir de conjuntos de dados desbalanceados. A ideia central do algoritmo é utilizar uma distribuição ponderada para gerar dados sintéticos de forma adaptativa para a classe minoritária, levando em consideração o nível de dificuldade de aprendizado de cada exemplo. Em termos práticos, o ADASYN gera uma quantidade maior de dados artificiais para as instâncias da classe minoritária que são mais difíceis de aprender (ou seja, aquelas cercadas por amostras da classe majoritária no espaço de atributos), enquanto gera menos dados para os exemplos considerados "fáceis".

Diferentemente do método SMOTE tradicional — que distribui de forma uniforme a geração de pontos sintéticos entre todas as instâncias da classe minoritária —, o ADASYN calcula a densidade local dos K vizinhos mais próximos de cada amostra para determinar automaticamente quantas novas instâncias devem ser sintetizadas a partir dela. Com isso, a técnica busca alcançar dois objetivos principais: diminuir o viés de classificação induzido pela disparidade entre as classes e deslocar adaptativamente a fronteira de decisão do modelo em direção às regiões onde o aprendizado é mais complexo. Além disso, como a atualização da distribuição de pesos é feita diretamente com base nas características geométricas dos dados, o ADASYN dispensa o custo computacional de reavaliar repetidamente hipóteses do classificador durante a síntese de amostragem.

3. Metodologia

3.1 Conjunto de Dados

O conjunto de dados (*dataset*) utilizado nesta pesquisa foi obtido a partir da plataforma oficial de dados geoespaciais da Embrapa (Geoinfo), referente ao mapeamento de solos do Brasil (Santos et al. 2011). O mapa original está na escala de 1:5.000.000 e utiliza o Sistema Brasileiro de Classificação de Solos (SiBCS). Para este trabalho, extraiu-se um recorte temporal e espacial cujos metadados detalhados foram acessados em abril de 2026\footnote{Disponível em: \url{https://geoinfo.dados.embrapa.br/datasets/geoinfo_data:geonode:brasil_solos_5m_20201104/metadata_detail}}.

O *dataset* consolidado para os experimentos totaliza 2.675 amostras, distribuídas em 13 classes de solos representativas do território nacional, além de 2 classes adicionais de superfícies não consolidadas ou rochosas (Dunas e Afloramentos de Rochas). A distribuição detalhada do quantitativo de amostras por classe, bem como a respectiva representatividade percentual sobre o total de dados, é apresentada na Tabela 1.

Tipos de Solo	Quant. de Amostra	Percentual do dataset (%)
Latossolos	677	25,308
Argissolos	583	21,794
Neossolos	463	17,308
Gleissolos	325	12,150
Plintossolos	178	6,654
Cambissolos	130	4,860
Espondossolos	90	3,364
Planassolos	66	2,467
Luvissolos	60	2,243
Nitossolos	48	1,794
Chernossolos	20	0,748
Afloramento de Rochas	13	0,486
Vertissolos	13	0,486
Organossolos	5	0,187
Dunas	4	0,150
TOTAL	2675	100,000

Tabela 1 - Quantidade de registros de solo no dataset

3.2. Ambiente de Codificação e Ferramentas

Para o desenvolvimento e execução dos experimentos desta pesquisa foi utilizada a plataforma em nuvem Google Colaboratory (Google Colab). A escolha desta ferramenta se deu pela facilidade de utilização em mais de uma máquina e também pela facilidade de compartilhamento do código, o que contribui para a reprodutibilidade desta pesquisa. Como linguagem de programação do ecossistema foi utilizado o Python em sua versão 3.10.12.

As bibliotecas em uso no projeto e suas respectivas funções no pipeline de classificação são detalhadas a seguir:

- **Pandas (versão 2.0.3):** Utilizada para a ingestão, estruturação, limpeza e manipulação do conjunto de dados tabulares da Embrapa;
- **Imbalanced-learn (versão 0.10.1):** Empregada especificamente para aplicar técnicas de reamostragem, atenuando o problema do desbalanceamento severo entre as classes de solo apresentadas na Tabela 1;
- **Scikit-learn (versão 1.2.2):** Utilizada como a biblioteca central para a modelagem preditiva, incluindo a divisão estratificada dos dados (treino/teste), validação cruzada, execução dos algoritmos de classificação e extração das métricas de avaliação;
- **Matplotlib (versão 3.7.1) e Seaborn (versão 0.13.1):** Adotadas em conjunto para a geração dos recursos visuais do artigo, tais como gráficos de distribuição de classes, curvas de aprendizado e matrizes de confusão.

3.3 Abordagem Proposta

Para a condução do experimento, avaliaram-se os algoritmos de aprendizado de máquina *Random Forest* e *k-Nearest Neighbors* (k-NN). O tratamento do desbalanceamento das classes foi realizado mediante a aplicação das técnicas de amostragem *SMOTE* e *ADASYN* em ambos os modelos. O dataset foi dividido em 70% para treinamento e 30% para teste, sendo que as técnicas *SMOTE* e *ADASYN* são utilizadas apenas no conjunto destinado ao treinamento do modelo. O desempenho das abordagens foi avaliado com base nas métricas de Precisão, *Recall* e *F1-Score*, cujos resultados e análises são discutidos nas seções subsequentes.

4. Resultados e Discussão

4.1. Análise Geral das Abordagens de Amostragem

Para avaliar a eficácia dos classificadores no tratamento do desbalanceamento de dados, realizaram-se experimentos comparativos combinando os algoritmos *Random Forest* e *k-Nearest Neighbors* (k-NN) às técnicas de sobreamostragem *Synthetic Minority Over-sampling Technique* (SMOTE) e *Adaptive Synthetic* (ADASYN). As abordagens foram testadas sob diferentes recortes de dados (Grupo 1 e Grupo 2) e configurações de hiperparâmetros (Normal e Otimizado). O grupo 1 é composto por um conjunto de 3 colunas do dataset (subordem1, gdegrupo1, area_km2) enquanto que o grupo 2 amplia essa lista e contém 6 colunas do dataset (subordem1, gdegrupo1, area_km2, subordem2, simbolos, compl).

A Tabela 2 sintetiza os resultados quantitativos obtidos nas métricas de Precisão, *Recall* e *F1-Score*, calculados sobre o conjunto de teste de forma a refletir a capacidade de generalização dos modelos em cenários distintos.

Modelo	Técnica de Balanceamento	Precisão	Recall	F1-Score
<i>Random Forest</i>	<i>Adasyn</i> - Grupo1	0,27	0,29	0,28
<i>Random Forest</i>	<i>Adasyn</i> - Grupo 2	1,00	1,00	1,00
<i>Random Forest</i>	<i>Smote</i> - Grupo 1	0,21	0,29	0,24
<i>Random Forest</i>	<i>Smote</i> - Grupo 2	0,85	0,79	0,81
<i>K-NN</i>	<i>Adasyn</i> - Normal	1,00	0,10	0,18
<i>K-NN</i>	<i>Adasyn</i> - Otimizado	1,00	0,60	0,75
<i>K-NN</i>	<i>Smote</i>	0,83	0,50	0,62

Tabela 2 - Desempenho dos modelos de classificação por técnicas de sobreamostragem

4.2. Análise Comparativa dos Modelos e Métodos

A análise do desempenho global indica diferenças substanciais no comportamento dos classificadores em função tanto do conjunto de dados/grupo avaliado quanto da técnica de reamostragem empregada.

4.2.1. O Desempenho do *Random Forest* e a Disparidade entre Grupos

A avaliação do *Random Forest* revelou comportamento divergente entre os grupos analisados. No Grupo 1, o modelo registrou baixo desempenho em todas as configurações, com *F1-Score* de 0,28 ao utilizar ADASYN e 0,24 ao utilizar o SMOTE. Esse resultado sugere elevado nível de ruído ou *overlap* entre as classes nesse subconjunto, o que limitou a capacidade do algoritmo em definir fronteiras de separação claras, mesmo após o balanceamento dos dados.

Em contrapartida, os melhores resultados do estudo foram obtidos no Grupo 2. A combinação do *Random Forest* com o SMOTE apresentou o desempenho mais consistente, alcançando precisão de 0,85, *recall* de 0,79 e *F1-Score* de 0,81. Os indicadores mostram que a sobreamostragem via SMOTE adensou a classe minoritária de forma homogênea no espaço de atributos, sem elevar a taxa de falsos positivos.

Embora o arranjo com ADASYN tenha atingido métricas máximas (1,00 em todos os índices) no Grupo 2, o resultado deve ser interpretado com ressalvas. Como o ADASYN concentra a geração de dados sintéticos nas zonas de fronteira mais complexas, a baixa variabilidade intrínseca dessa base pode ter levado à criação de instâncias praticamente idênticas às originais, induzindo o modelo ao *overfitting*. Por essa razão, a abordagem com SMOTE consolida-se como a opção mais estável para o Grupo 2.

4.2.2. O Impacto da Otimização no *k-NN* e a Sensibilidade do Espaço Geométrico

A estrutura baseada em vizinhança do k-NN mostrou-se bastante sensível às etapas de pré-processamento e ajuste do modelo. No arranjo k-NN + ADASYN sem otimização, apesar da precisão unitária (1,00), a sensibilidade atingiu apenas 0,10, resultando em um *F1-Score* de 0,18. O desempenho reflete a tendência do k-NN em ser dominado pela densidade local da classe majoritária quando os hiperparâmetros (como o valor de k e a métrica de distância) não estão devidamente ajustados.

A otimização dos hiperparâmetros na combinação k-NN + ADASYN alterou esse comportamento: mantendo a precisão em 1,00, a sensibilidade subiu para 0,60, elevando o *F1-Score* para 0,75 (um ganho de 0,57 em relação ao modelo padrão).

Por sua vez, a configuração k-NN + SMOTE apresentou desempenho intermediário (*F1-Score* de 0,62, precisão de 0,83 e sensibilidade de 0,50). A diferença entre os métodos indica que a geração adaptativa do ADASYN, quando associada ao ajuste do classificador, alinha-se melhor à topologia do k-NN do que a interpolação linear uniforme do SMOTE.

4.3. Discussão sobre as Matrizes de Confusão

O comportamento preditivo dos modelos foi avaliado a partir de sete matrizes de confusão. Para detalhar os padrões de erro e acerto, adotou-se como referência o desempenho do *Random Forest* com ADASYN no Grupo 1 (Figura 3), focando a análise na ordem dos Nitossolos.

A matriz revela dificuldades significativas na identificação dos Nitossolos: das 14 instâncias reais da classe, o modelo acertou apenas 4 (recall de 0,28), registrando 10 falsos negativos. Os erros concentraram-se principalmente nos Argissolos (3 amostras) e Latossolos (3 amostras), com classificações pontuais em Planossolos e Plintossolos. Esse espalhamento mostra a limitação do algoritmo em definir limites claros para os Nitossolos a partir dos atributos do Grupo 1.




Figura 3 - Matriz de confusão da classificação de solos – ADASYN Grupo 1.

Sob a perspectiva pedológica, a confusão entre Nitossolos, Argissolos e Latossolos reflete a transição gradual de suas propriedades na paisagem. Os Nitossolos possuem horizonte B nítico com alta fração argilosa, estrutura em blocos e cerosidade — feições que se sobrepõem fisicamente aos Latossolos (homogêneos e argilosos) e aos Argissolos (com B textural). Ao atuar sobre a base do Grupo 1, a geração de dados sintéticos pelo ADASYN interpolou amostras justamente nessas zonas de sobreposição *overlap*, induzindo o modelo ao erro.

O viés de classificação foi acentuado pelo predomínio de classes majoritárias, como os Latossolos (140 acertos e 61 confusões com Argissolos) e os Argissolos (101 acertos e 66 confusões com Latossolos). A densidade dessas ordens atraiu a fronteira de decisão, fazendo com que parte dos Nitossolos fosse absorvida por elas. Esse comportamento inicial serviu de base para comparar as demais matrizes, nas quais a mudança para o Grupo 2 e a otimização dos hiperparâmetros reduziram a influência das classes dominantes e elevaram o acerto dos Nitossolos.

A análise da matriz do *Random Forest* com ADASYN no Grupo 2 (Figura 4) indica um comportamento oposto ao observado no Grupo 1. Nessa configuração, o modelo alcançou sensibilidade máxima na maioria das ordens de solo, com acerto de 100% nas instâncias de Nitossolos (14 de 14 amostras), sem registros de falsos positivos ou falsos negativos.




Figura 4 - Matriz de confusão da classificação de solos – ADASYN Grupo 2.

Embora as confusões entre Nitossolos, Latossolos e Argissolos tenham sido eliminadas, esse resultado sugere a ocorrência de *overfitting*. A separação perfeita entre classes pedológicas com transições contínuas na paisagem é atípica e indica que o ADASYN concentrou as amostras sintéticas excessivamente próximas dos exemplos reais da classe minoritária. Diante da menor variabilidade de atributos do Grupo 2, essa interpolação fez o *Random Forest* memorizar as fronteiras de decisão, criando um cenário de separabilidade idealizado.

Assim, os índices perfeitos obtidos nessa configuração devem ser interpretados com cautela quanto à capacidade de generalização para novos dados de campo. A transição entre os experimentos mostra que, enquanto o Grupo 1 apresentou acentuada sobreposição entre as

ordens, o Grupo 2 com ADASYN tendeu ao extremo oposto, gerando um ambiente simplificado para a classificação dos Nitossolos.

A análise da matriz terceira matriz, que apresenta a configuração de *Random Forest* com SMOTE no Grupo 1 (Figura 5), permite comparar a interpolação linear simples com a geração adaptativa do ADASYN. Para os Nitossolos, o desempenho do modelo foi idêntico ao observado no primeiro cenário: das 14 instâncias reais, apenas 4 foram classificadas corretamente, enquanto as 10 restantes dividiram-se entre Argissolos (3 amostras), Latossolos (3 amostras), Planossolos e Plintossolos.




Figura 5 - Matriz de confusão da classificação de solos – SMOTE Grupo 1.

A reprodução exata do padrão de erros para os Nitossolos nas duas primeiras técnicas de balanceamento do Grupo 1 evidencia uma importante constatação pedológica e metodológica: o baixo desempenho de detecção dessa classe não decorre de deficiências específicas no algoritmo de sobreamostragem empregado, mas sim da intrínseca proximidade físico-espectral que os Nitossolos mantêm com as ordens dos Latossolos e Argissolos. Sob o

conjunto de atributos do Grupo 1, a presença de gradientes teores de argila e feições estruturais de transição impede que tanto a interpolação linear uniforme (*SMOTE*) quanto a focada em fronteiras (*ADASYN*) estabeleçam hiperplanos de separação eficazes para os Nitossolos.

Adicionalmente, a matriz do *SMOTE* – Grupo 1 exibiu uma polarização ainda mais acentuada em direção à classe majoritária dos Argissolos, que absorveu incorretamente 82 amostras de Latossolos (frente a 61 registradas na matriz do *ADASYN*). Esse aumento na taxa de falsos positivos para os Argissolos corrobora o F1-score inferior obtido pelo *SMOTE* no Grupo 1 (0,24), demonstrando que a síntese linear sem ponderação de densidade tendeu a inflar o espaço de atributos da classe dominante, mantendo a classe dos Nitossolos sub-representada na diagonal principal.

A análise da quarta matriz de confusão, referente ao *Random Forest* com *SMOTE* no Grupo 2 (Figura 6), apresenta a configuração mais consistente do estudo. Ao contrário do superajuste observado no cenário com *ADASYN*, a combinação do modelo com o *SMOTE* no Grupo 2 demonstrou boa capacidade de generalização, atingindo altas taxas de acerto sem eliminar as pequenas ambiguidades esperadas no mapeamento de dados pedológicos.




Figura 6. Matriz de confusão da classificação de solos – SMOTE Grupo 2

Em relação aos Nitossolos, o modelo obteve um ganho expressivo de desempenho em comparação ao Grupo 1: das 14 instâncias reais, 11 foram classificadas corretamente (recall = 0,78), com apenas 3 omissões divididas entre Planossolos (1 amostra) e Plintossolos (2 amostras). Sob a ótica da precisão, das 13 predições atribuídas aos Nitossolos, 11 estavam corretas, com apenas 2 falsos positivos oriundos de Argissolos. A redução substancial das confusões entre Nitossolos, Latossolos e Argissolos indica que a seleção de atributos do Grupo 2 aliada à sobreamostragem do SMOTE permitiu definir fronteiras de separação claras para a classe alvo.

Além disso, o modelo preservou pequenas ambiguidades esperadas entre as ordens majoritárias, como a classificação incorreta de 5 Argissolos como Latossolos e de 2 Latossolos como Argissolos — comportamento coerente com os gradientes contínuos do solo na paisagem. Por equilibrar alta sensibilidade nos Nitossolos e um padrão de erro condizente com a variabilidade natural, o arranjo *Random Forest* + SMOTE no Grupo 2 consolida-se como o melhor resultado da pesquisa, sustentando os índices descritos na Tabela 2 (*F1-Score* = 0,81).

A análise da matriz de confusão do k-NN com SMOTE (Figura 7) indica um padrão de erro decorrente do impacto da sobreamostragem nas métricas de distância do algoritmo.




Figura 7 - Matriz de confusão da classificação de solos – *k*-NN + SMOTE.

Para os Nitossolos, o modelo identificou corretamente 7 das 14 instâncias (recall = 0,50). O aspecto relevante reside na distribuição dos erros: em vez da sobreposição comum com Latossolos ou Argissolos, todas as 7 amostras de Nitossolos omitidas foram classificadas como Afloramentos de Rochas. Por outro lado, a precisão para os Nitossolos foi máxima, pois nenhuma outra classe foi incorretamente atribuída a essa categoria, indicando alta seletividade na definição de suas fronteiras.

Essa tendência de classificação em direção aos Afloramentos de Rochas ocorreu de forma generalizada na maioria das ordens, afetando 61 Argissolos, 47 Latossolos e 21 Neossolos. Do ponto de vista metodológico, o comportamento reflete a sensibilidade do *k*-NN à distribuição das amostras geradas pelo SMOTE. Como a interpolação linear do SMOTE não pondera a densidade local, o algoritmo pode criar instâncias sintéticas em zonas limítrofes. Devido à menor variabilidade interna da classe de rochas, esses pontos sintéticos reduziram a distância euclidiana em relação a amostras de solos reais, alterando a contagem dos *k* vizinhos mais próximos.

O fenômeno explica o F1-Score intermediário do *k*-NN + SMOTE (F1-Score = 0,62). Embora a configuração tenha evitado falsos positivos nos Nitossolos, as distorções no espaço de atributos reduziram a sensibilidade global. O resultado sinaliza que classificadores baseados em vizinhança exigem ajustes de hiperparâmetros ou seleção prévia de atributos para mitigar os efeitos da sobreamostragem linear em zonas de fronteira.

A análise da matriz do *k*-NN com ADASYN sem otimização de hiperparâmetros (Figura 8) detalha as causas do baixo desempenho da abordagem (F1-Score = 0,18), evidenciando o impacto da síntese adaptativa não ajustada sobre classificadores baseados em distância.




Figura 8 - Matriz de confusão da classificação de solos – k -NN + ADASYN. .

Para os Nitossolos, o modelo apresentou baixa capacidade de detecção: das 14 instâncias reais, apenas 1 foi classificada corretamente, registrando 13 falsos negativos. As incorreções não decorreram da sobreposição morfológica com Latossolos ou Argissolos, mas do direcionamento incorreto das previsões para a classe das Dunas. A precisão dos Nitossolos permaneceu em 1,00 porque a única estimativa atribuída à classe esteve correta, o que explica a divergência entre as métricas (precisão unitária e sensibilidade de 0,10).

A classificação indevida na categoria Dunas ocorreu em quase todas as ordens avaliadas, afetando 62 Argissolos, 34 Latossolos, 30 Neossolos e 25 Plintossolos. Do ponto de vista metodológico, esse resultado mostra a sensibilidade do k -NN padrão à densidade de amostras gerada pelo ADASYN. Como o algoritmo concentra a síntese de dados em regiões de maior complexidade, a classe Dunas recebeu um volume elevado de instâncias sintéticas em zonas periféricas do espaço de atributos. Sem o ajuste do número de vizinhos (k) ou a ponderação por distância, essa concentração alterou a vizinhança local, deslocando as fronteiras em favor da classe Dunas.

Esses resultados indicam que o uso do ADASYN com k-NN sem ajuste prévio pode alterar a topologia do espaço amostral e comprometer a identificação de ordens como os Nitossolos. Essa limitação justifica a etapa de otimização de hiperparâmetros do k-NN, na qual a adequação da vizinhança permitiu reduzir o viés observado e recuperar a sensibilidade do modelo.

A análise da matriz do k-NN com ADASYN após a otimização de hiperparâmetros (Figura 9) demonstra o efeito do ajuste de vizinhança na recuperação do desempenho do modelo, relacionando-se ao aumento no *F1-Score* (de 0,18 para 0,75, conforme apresentado na Tabela 2).




Figura 9 - Matriz de confusão da classificação de solos – k-NN + ADASYN Otimizado.

Para a ordem dos Nitossolos, a otimização elevou a sensibilidade do modelo: das 14 instâncias reais, o k-NN otimizado identificou corretamente 7 amostras na diagonal principal. Embora as 7 omissões restantes ainda tenham sido classificadas como Dunas, a precisão para a categoria manteve-se em 1,00, sem o registro de falsos positivos.

Além do ganho na detecção dos Nitossolos, a Figura 9 indica a redução do viés em direção à classe Dunas. O ajuste dos parâmetros de distância e do número de vizinhos (k) redefiniu as fronteiras locais, diminuindo as classificações incorretas em ordens majoritárias — como a redução de 62 para 27 Argissolos e de 34 para 13 Latossolos associados indevidamente a Dunas. Esse rearranjo tornou a diagonal principal mais bem definida para a maioria das classes.

A comparação entre o k -NN padrão e a versão otimizada sob o ADASYN indica que, embora o método de amostragem possa alterar a densidade local em espaços não ajustados, a otimização do classificador mitiga essas distorções, recuperando a capacidade de identificação de ordens como os Nitossolos sem comprometer a precisão.

5. Conclusão

5.1. Considerações Finais

O mapeamento digital de Nitossolos no Brasil enfrenta limitações associadas à baixa representatividade dessas ordens nas bases geoespaciais oficiais. Ao constituírem menos de 2% do acervo da Embrapa, esses solos tendem a ser subestimados por classificadores convencionais, que favorecem as classes majoritárias. Para contornar essa restrição, este estudo avaliou a integração entre técnicas de sobreamostragem (*SMOTE* e *ADASYN*), ampliação do conjunto de atributos e otimização dos algoritmos *Random Forest* e k -NN para o reconhecimento automatizado da ordem.

Os resultados indicam que o tratamento do desbalanceamento depende da estrutura do espaço de atributos e do princípio de funcionamento do algoritmo adotado. O conjunto inicial de dados (Grupo 1), restrito a três atributos, mostrou-se insuficiente para discriminar os Nitossolos frente aos Argissolos e Latossolos, devido às semelhanças físicas e mineralógicas entre essas classes. A inclusão de novas variáveis no Grupo 2 forneceu a resolução necessária para definir limites de separação mais condizentes com a realidade de campo.

Entre as configurações analisadas, a combinação do *Random Forest* com o *SMOTE* no Grupo 2 apresentou o desempenho mais consistente. O modelo alcançou recall de 78% e precisão de 85% para os Nitossolos ($F1\text{-Score} = 81\%$), preservando pequenas ambiguidades de borda esperadas em gradientes pedológicos contínuos. Em contrapartida, embora a combinação de *Random Forest* com *ADASYN* no Grupo 2 tenha atingido métricas máximas (1,00), a análise das matrizes de confusão indicou ocorrência de *overfitting*, decorrente da concentração de amostras sintéticas em um espaço com baixa variabilidade.

A avaliação do k -NN evidenciou a sensibilidade dos métodos baseados em distância às alterações de densidade provocadas pela geração de dados sintéticos. Sem o ajuste de parâmetros, o algoritmo tendeu a classificar incorretamente instâncias em categorias específicas, como Dunas ou Afloramentos de Rochas. Contudo, o ajuste da métrica de distância e do número de vizinhos (k) na configuração k -NN + *ADASYN* elevou o $F1\text{-Score}$ de

0,18 para 0,75, recuperando a sensibilidade para a classe dos Nitossolos sem comprometer a precisão.

Em resumo, a pesquisa demonstra que a identificação de ordens minoritárias como os Nitossolos é viável quando a sobreamostragem é combinada à seleção adequada de preditores e ao ajuste de hiperparâmetros dos classificadores.

5.2. Limitações

Algumas limitações metodológicas devem ser consideradas na interpretação dos resultados obtidos. Primeiramente, o número reduzido de dados originais para a classe dos Nitossolos, constituído por 48 registros reais na base nacional, delimitou o conjunto de validação em apenas 14 amostras. Embora as técnicas de sobreamostragem auxiliem na definição das fronteiras durante o treinamento, o reduzido tamanho do subconjunto de teste requer cautela na extrapolação das métricas para escalas nacionais.

Adicionalmente, a escala cartográfica da base de dados utilizada (1:5.000.000) impõe restrições ao nível de detalhamento dos resultados. Essa resolução atende a análises regionais e de planejamento macro, mas não apresenta o grau de detalhamento exigido para aplicações locais ou em nível de propriedade rural.

Sob o aspecto metodológico, destaca-se o risco de delimitação artificial de fronteiras, observado no arranjo do *Random Forest* com ADASYN no Grupo 2. A síntese adaptativa em conjuntos com reduzida variabilidade pode gerar métricas perfeitas no conjunto de teste que não refletem a continuidade física das classes no campo.

Por fim, verificou-se a sensibilidade do algoritmo k-NN às alterações na topologia do espaço de atributos decorrentes da sobreamostragem. O comportamento do modelo sinaliza que classificadores baseados em distância exigem etapas específicas de seleção de variáveis e ajuste de hiperparâmetros para evitar distorções na contagem dos vizinhos mais próximos.

5.3. Trabalhos Futuros

Para a continuidade e o aprofundamento desta pesquisa, recomendam-se algumas diretrizes metodológicas. A primeira consiste na incorporação de dados de sensoriamento remoto e variáveis topográficas derivadas de Modelos Digitais de Elevação (MDE), tais como declividade, índice de umidade e séries temporais de índices espectrais (ex.: NDVI). A inclusão desses preditores pode enriquecer o espaço de atributos e fornecer maior suporte à discriminação das ordens de solo.

Sob a perspectiva do pré-processamento de dados, sugere-se a exploração de métodos híbridos de sobreamostragem e filtragem, a exemplo do SMOTE-Tomek e SMOTE-ENN. Essas abordagens combinam a geração sintética com a remoção de instâncias ruidosas ou ambíguas nas zonas de fronteira, o que pode reduzir a sobreposição entre as classes.

Em termos de modelagem, é oportuno avaliar o desempenho de algoritmos baseados em *Gradient Boosting*, como XGBoost, LightGBM e CatBoost, verificando a eficácia de suas funções de perda no tratamento direto do desbalanceamento sem a necessidade de síntese de dados.

Do ponto de vista de validação, recomenda-se a adoção de estratégias de validação cruzada espacial. Essa abordagem minimiza os efeitos da autocorrelação espacial entre os pontos de treino e teste, prevenindo estimativas super otimistas decorrentes do vazamento de dados (*data leakage*).

Por fim, propõe-se a aplicação prática da configuração *Random Forest* + SMOTE em um mapeamento piloto regional em áreas conhecidas por expressiva ocorrência de Nitossolos (como setores das regiões Sul e Sudeste), permitindo confrontar a probabilidade de ocorrência estimada pelo modelo com verificações de campo.

6. Referências

BREIMAN, Leo. Random Forests. **Machine Learning**, [S. l.], v. 45, n. 1, p. 5-32, 2001

CHAWLA, Nitesh V. *et al.* SMOTE: Synthetic Minority Over-sampling Technique. **Journal of Artificial Intelligence Research**, [S. l.], v. 16, p. 321-357, 2002.

HE, Haibo et al. ADASYN: Adaptive synthetic sampling approach for imbalanced learning. **In: IEEE INTERNATIONAL JOINT CONFERENCE ON NEURAL NETWORKS (IJCNN 2008)**, 2008, Hong Kong. **Proceedings...** [S. l.]: IEEE, 2008. p. 1322-1328.

KOCH, Andrea et al. Soil Security: Solving the Global Soil Crisis. *Global Policy*, v. 4, n. 4, p. 434–441, nov. 2013.

SANTOS, H. G. dos, Carvalho Junior, W. de, Dart, R. de O., Aglio, M. L. D., Sousa, J. S. de, Pares, J. G., Fontana, A., Martins, A. L. da S., e Oliveira, A. P. de (2011). O novo mapa de solos do Brasil: legenda atualizada. Embrapa Solos. Documentos, 130. Rio de Janeiro.

SANTOS, Humberto Gonçalves dos, et al. **Sistema Brasileiro de Classificação de Solos**. 5. ed. rev. e ampl. Brasília, DF: Embrapa, 2018. 356 p. ISBN 978-85-7035-800-4

SERRA DA CRUZ, Sergio Manuel et al. OpenSoils: e-Science em Segurança de Solos. [S.l.: S.n.]. Disponível em: <<https://www.researchgate.net/publication/326977225>>.